ניטור מטיילים מבוסס חיישני BLE — דוח מצב נוכחי ומתודולוגיה

דוח מחקר מסכם | 30 ביולי 2026 | שלבים א׳–ג׳ מתוך ד׳ הושלמו

תוכן העניינים

1. רקע ומטרת המחקר
2. תיאור הנתונים
3. שיטת העבודה — שלב א׳: ניקוי והכנת נתונים
4. שיטת העבודה — שלב ב׳: חלוקה ל"ביקורים" (Sessionization)
5. שיטת העבודה — שלב ג׳: איחוד זהויות (Entity Resolution)
6. תוצאות מסכמות: מטיילים ליום
7. יתרונות ומגבלות של הגישה הכוללת
8. השלב הבא: שלב ד׳ — זיהוי כיוון תנועה

641,804	815,093	10,516 / 7,961	30
קריאות חיישן A לאחר ניקוי	קריאות חיישן B לאחר ניקוי	מטיילים ייחודיים (A / B) לאחר איחוד זהויות	ימי איסוף נתונים שונים

1. רקע ומטרת המחקר

מטרת המחקר היא לפתח שיטה זולה ואמינה לספירת מטיילים בשטחים פתוחים (שמורות טבע, שבילים), המבוססת על חיישני Bluetooth Low Energy (BLE) מחוברים לבקר Arduino. חלופות כמו מצלמות או חיישני אינפרה-אדום נפסלו מראש בשל עלות, צורך בקו-ראייה ישיר, ובעיות פרטיות (צילום מבקרים); חיישני BLE פסיביים — שאינם דורשים כל פעולה מצד המטייל, אלא רק "מאזינים" לשידורי הפרסום (advertisement) שהטלפון או השעון החכם שלו משדרים ממילא — הם החלופה הזולה והלא-פולשנית ביותר.

לגישה זו שני קשיים מובנים, ששניהם גורמים ל**ספירת יתר** אם לא מטופלים:

- **ריבוי מכשירים:** מטייל אחד עשוי לשאת מספר מכשירים משדרים (טלפון, שעון, אוזניות אלחוטיות) — כל אחד מהם נספר, בטעות, כמטייל נפרד.
- **MAC Randomization:** מטעמי פרטיות, מכשירים מודרניים משנים את כתובת ה-MAC שלהם מדי כמה דקות. מכשיר בודד שנשאר באזור זמן ארוך עשוי להירשם תחת כמה כתובות MAC שונות ברצף, ולהיספר כמה פעמים.

מכיוון ש**אין נתוני אמת (ground truth)** — אין רשימה מאומתת שמקשרת כתובת MAC למטייל ספציפי — הפתרון חייב להתבסס על **למידה בלתי מונחית** (unsupervised learning): זיהוי דפוסים בנתוני העוצמה (RSSI) והזמן בלבד, ללא תיוג חיצוני. הפתרון נבנה כצינור עיבוד (pipeline) בן ארבעה שלבים, המתועד גם בקובץ `hiker_monitoring_project_summary.md`. דוח זה מציג את המתודולוגיה המלאה ואת כלל התוצאות של שלושת השלבים שהושלמו עד כה.

2. תיאור הנתונים

בשטח פרוסים שני חיישנים — **A** ו-**B** — במרחק קצר זה מזה לאורך אותו שביל, עם אזור חפיפה בקליטה ביניהם (הנדרש בהמשך לזיהוי כיוון תנועה, שלב ד׳). כל קריאת חיישן כוללת כתובת MAC, עוצמת קליטה (RSSI, ב-dBm) וחותמת זמן ברזולוציית שניות. הנתונים מגיעים כקבצי ייצוא (CSV/XLSX) נפרדים, שנאספו על פני תקופות שונות ואוחדו לשני קבצים מרכזיים — אחד לכל חיישן.

מאפיין	חיישן A	חיישן B
טווח תאריכים גולמי	31.05.2026 – 03.01.2026	31.05.2026 – 09.04.2026
קבצי מקור	8	7
שורות גולמיות (לפני ניקוי)	949,211	1,217,216
שורות לאחר ניקוי כפילויות	641,804	815,093
כתובות MAC ייחודיות (גולמי)	14,625	18,781
ימי איסוף שונים בפועל	21	23

21 + 23 גדול מ-30 (סך כל הימים השונים) מכיוון שיש חפיפה: 14 ימים נאספו בשני החיישנים במקביל (ראו סעיף 6).

קבצי המקור, לפי חיישן

חיישן A

קובץ	לפני	אחרי	הוסרו
`data_A_260526.csv`	491,377	338,054	153,323
`data230526a.csv`	306,652	152,783	153,869
`data_090526A.csv`	52,526	52,462	64
`data_A300526.csv`	43,031	42,972	59
`dataA_110426_1_good.csv`	34,125	34,077	48
`data_A_020526.csv`	15,567	15,542	25
`data_A_030126.xlsx`	3,569	3,550	19
`data_310526A.csv`	2,364	2,364	0

חיישן B

קובץ	לפני	אחרי	הוסרו
`data_b_260526.csv`	507,226	307,464	199,762
`data230526b.csv`	401,055	199,111	201,944
`data_B_300526.csv`	166,030	165,849	181
`data_090526B.csv`	109,719	109,529	190
`dataB_110426_1.csv`	23,126	23,096	30
`data_B_020526.csv`	8,055	8,042	13
`data_B_310526.csv`	2,005	2,002	3

קובץ `data_A_030126.xlsx`: קובץ זה נוסף לאחרונה ומהווה חלון של כשעה (11:31–12:30) בתאריך 03.01.2026 — כחודשיים לפני תחילת שאר נתוני חיישן A. אין לתאריך זה נתוני חיישן B מקבילים, כך שהוא אינו יכול לשמש לניתוח כיוון תנועה (שלב ד׳) ומדווח כאן רק בהיבט הספירה החד-חיישנית.

3. שיטת העבודה — שלב א׳: ניקוי והכנת נתונים

המטרה

להביא את נתוני שני החיישנים למצב "נקי" ואחיד: ללא כפילויות, וממוין כרונולוגית, כבסיס לכל שלבי ההמשך.

איך השיטה עובדת

קבצי המקור הם לעיתים **ייצוא מצטבר (cumulative export)** של אותו יומן מכשיר — קובץ שנשמר בתאריך מאוחר יותר מכיל בתוכו את כל השורות שכבר היו בקובץ מוקדם יותר, בנוסף לשורות חדשות (לדוגמה: `data230526a.csv` הוא כמעט תת-קבוצה מלאה של `data_A_260526.csv`). כתוצאה מכך, איחוד פשוט של כל הקבצים יוצר כפילויות מדויקות של אותה קריאה ממש. הניקוי מתבצע על ידי הגדרת "מפתח זהות" לכל קריאה — השילוש `(MAC, RSSI, timestamp)` — והסרת כל שורה שהמפתח שלה כבר הופיע קודם באוסף (`drop_duplicates` לפי שלושת העמודות יחד, תוך שמירה על השורה הראשונה בלבד).

למה נבחרה השיטה הזו

מפתח מדויק בן שלוש עמודות (ולא, למשל, רק MAC וזמן) נבחר במכוון: שתי קריאות עוקבות של אותו MAC באותה שנייה בדיוק עם עוצמות RSSI *שונות* הן קריאות אמיתיות ושונות (רעש טבעי בסריקת BLE), ולא כפילות-ייצוא — ומיזוגן היה גורם לאובדן מידע אמיתי. בפרויקט זה כבר נתקלנו במעבר מגרסת קלט ישנה שרשמה רק דקות (ללא שניות) לגרסה נוכחית שרושמת שניות מדויקות לכל שורה; כאשר הזמן היה ברזולוציית דקה, אותו מפתח דדופ יצר **ספירת חסר** (קריאות אמיתיות שונות באותה דקה התנגשו ונחשבו בטעות לכפילות). כעת, כשכל שמונת/שבעת קבצי המקור כוללים שניות מדויקות, מפתח הזהות המדויק הזה בטוח ומדויק.

יתרונות:

- דטרמיניסטי ופשוט להסבר — אין הימור סטטיסטי, רק זהות מדויקת.
- לא מאבד מידע: כל קריאה שונה במשהו (RSSI או זמן) נשמרת.
- מהיר לחישוב על מיליוני שורות (פעולת hash פשוטה).

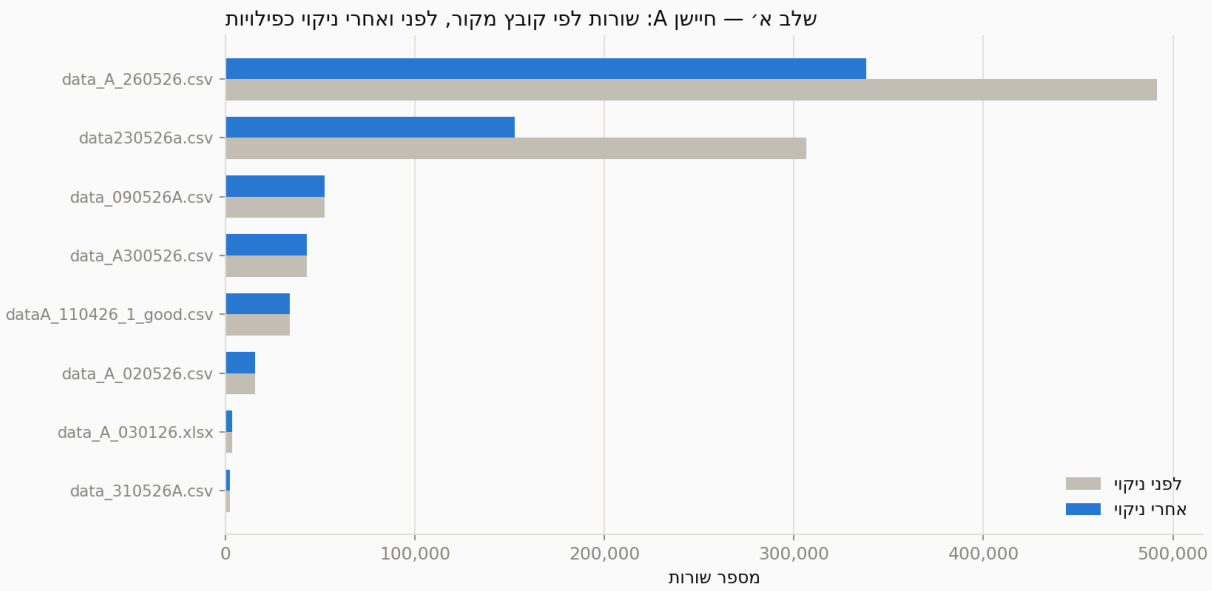
מגבלות:

- רגיש לרזולוציית חותמת הזמן במקור — אם קובץ עתידי יגיע שוב ברזולוציית דקה בלבד, הבעיה ההיסטורית תחזור.
- לא מזהה "כמעט-כפילויות" (הפרש RSSI של 1dB או שנייה בודדת בין שני קבצים עקב שעון לא מסונכרן בין ייצואים) — לא נבדק אם תופעה כזו קיימת.

תוצאות

חיישן	שורות לפני ניקוי	שורות אחרי ניקוי	כפילויות שהוסרו	אחוז שהוסר
A	949,211	641,804	307,407	32.4%
B	1,217,216	815,093	402,123	33.0%

כשליש מהשורות בכל חיישן הן כפילויות-ייצוא — עקבי בין שני החיישנים, תומך בכך שהתופעה נובעת משיטת הייצוא ולא מתקלה נקודתית בקובץ בודד.



שורות לכל קובץ מקור (חיישן A), לפני ואחרי ניקוי. שני הקבצים הגדולים (`data_A_260526` , `data230526a`) מאבדים הכי הרבה שורות — עקבי עם היותם ייצוא מצטבר של אותו יומן.

תוצרים

קובץ	תיאור
`DATA/sensor_A_deduped.csv / .parquet`	641,804 שורות — נתוני חיישן A לאחר ניקוי
(ניקוי חיישן B מבוצע כצעד מקדים בתוך שלב ב׳)	815,093 שורות

4. שיטת העבודה — שלב ב׳: חלוקה ל"ביקורים" (Sessionization)

המטרה

לקבץ קריאות RSSI גולמיות של אותה כתובת MAC, בכל חיישן בנפרד, ל"ביקורים" (sessions) רציפים — פרק זמן אחד שבו המכשיר היה בטווח הקליטה — ולחלץ עבור כל ביקור מאפיינים מסכמים שישמשו את שלב האיחוד (שלב ג׳).

איך השיטה עובדת

עבור כל כתובת MAC בנפרד, ממיינים את הקריאות לפי זמן ומודדים את הפער (בשניות) בין כל קריאה לקודמתה. כאשר הפער עולה על **סף של 60 שניות**, נפתח ביקור חדש. זהו למעשה אלגוריתם קיבוץ חד-מימדי (מרחק = זמן בלבד) מסוג "שרשור פשוט" ברמת כל MAC בנפרד — פשוט מ-DBSCAN, אך יעיל באותה מידה כשהמימד הוא זמן בלבד ומסודר. לכל ביקור מחושבים: זמן התחלה/סיום, משך, מספר קריאות, RSSI ממוצע, ו**מגמת RSSI** — שיפוע קו הרגרסיה הליניארית (least squares) של RSSI כנגד הזמן בתוך הביקור, ביחידות dBm/שנייה.

למה נבחר סף של 60 שניות, ולמה מגמת RSSI

הסף נקבע **אמפירית** מתוך התפלגות הפערים בין קריאות עוקבות באותו MAC: החציון הוא שנייה אחת בלבד, ו-99.9% מהפערים קטנים או שווים ל-60 שניות. זוהי נקודת החיתוך הטבעית בין "המכשיר עדיין נמצא באזור הקליטה" (פערים קצרים, תואמים למרווחי פרסום BLE טיפוסיים) לבין "המכשיר עזב וחזר" (פערים ארוכים בהרבה — לרוב ימים שלמים בין ביקורים). מגמת ה-RSSI נבחרה כמאפיין מרכזי מכיוון שהיא אינה תלויה בעוצמת השידור המוחלטת של המכשיר (שמשתנה בין דגמים) — היא לוכדת רק את **הכיוון** (מתקרב/מתרחק), שהוא בדיוק המידע הדרוש כדי לזהות בהמשך אם שתי "כתובות" שונות בעצם מתארות את אותה תנועה פיזית.

יתרונות:

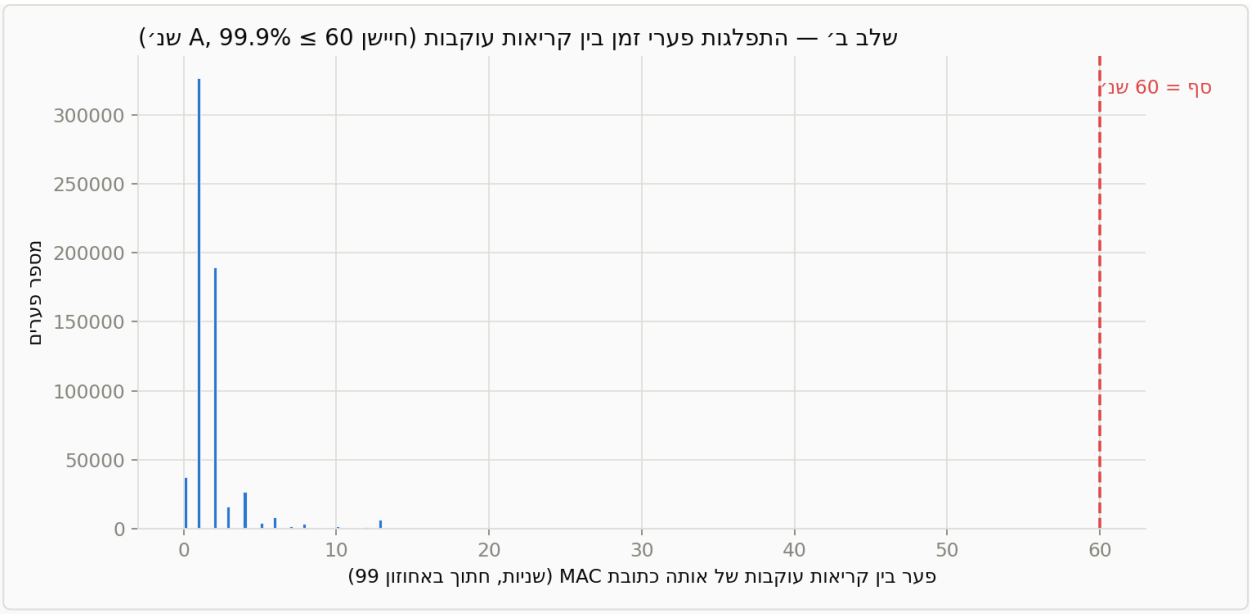
- סף יחיד ופשוט, נגזר ישירות מהנתונים ולא משוער.
- מגמת RSSI היא סקלר בודד המסכם "צורת" הביקור בלי צורך ביישור עקומות (DTW) יקר חישובית.
- ביקורים של קריאה בודדת (n_readings=1) **נשמרים** ולא נזרקים — עדיין עשויים לייצג מכשיר שחלף בקצה הטווח.

מגבלות:

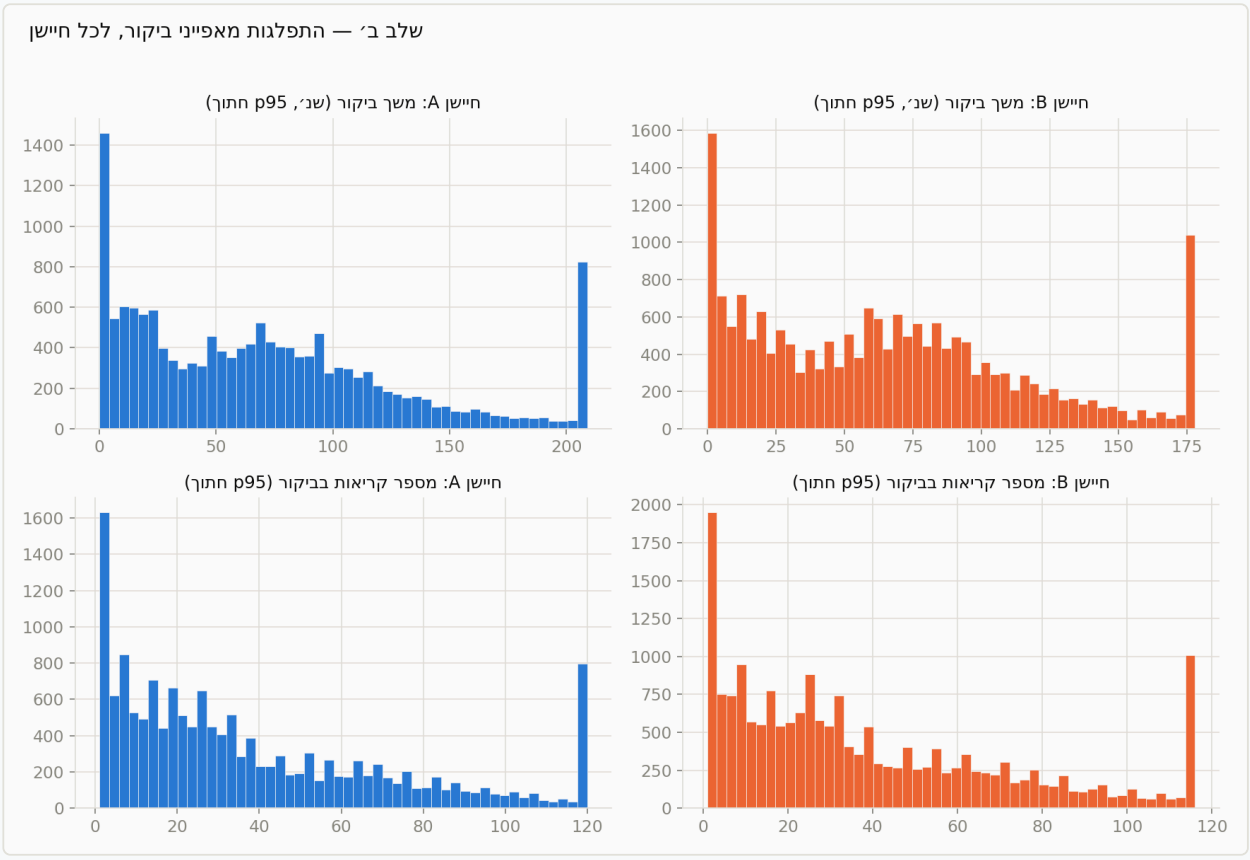
- סף גלובלי אחד לכל הנתונים — לא מתאים את עצמו לפי אזור, שעה ביום או קצב הליכה שונה.
- מטייל שעצר לתצפית/תמונה ליותר מ-60 שניות עלול להיפצל לשני ביקורים (אם כי שלב ג׳ עשוי לאחד אותם בחזרה אם המגמה דומה).
- שיפוע רגרסיה ליניארית הוא תיאור גס — לא לוכד תנועה לא-מונוטונית (התרחקות והתקרבות בתוך אותו ביקור).
- עבור ביקורי קריאה-בודדת אין מגמה מוגדרת כלל (NaN) — נדרש מנגנון גיבוי בשלב ג׳ (ראו שם).

תוצאות

חיישן	קריאות (לאחר ניקוי)	ביקורים (sessions)	ביקורי קריאה-בודדת	ביקורי רב-קריאה
A	641,804	15,267	649 (4.3%)	14,618
B	815,093	19,359	801 (4.1%)	18,558



התפלגות הפערים בין קריאות עוקבות של אותה כתובת MAC (חיישן A, חתוכה באחוזון 99 להצגה). רוב הפערים מתרכזים קרוב לאפס; קו הסף (60 שניות, אדום) נמצא הרחק בזנב ההתפלגות — 99.9% מהפערים קטנים ממנו.



התפלגות משך הביקור ומספר הקריאות לביקור, בשני החיישנים בנפרד — צורות דומות מאוד בין A ל-B, סימן לעקביות בין שני הצינורות הנפרדים לחלוטין.

תוצרים

קובץ	תיאור
`DATA/sessions_sensor_A / B .csv / .parquet`	טבלת ביקורים לכל חיישן, עם כל המאפיינים

5. שיטת העבודה — שלב ג': איחוד זהויות (Entity Resolution)

המטרה

לאחד כתובות MAC שונות ששייכות ככל הנראה לאותו מטייל פיזי (בשל ריבוי מכשירים או שינוי MAC באמצע ביקור) תחת מזהה מטייל יחיד (`Traveler_ID`). הפעולה מתבצעת בנפרד עבור כל חיישן.

איך השיטה עובדת

שלב 1 — חסימה בזמן (Blocking): השוואת כל זוג ביקורים אפשרי בכל הנתונים היא $O(n^2)$ ובלתי אפשרית בפועל (מיליוני זוגות). לכן, ביקורים מחולקים תחילה ל"בלוקים" רציפים בזמן — כל אימת שיש פער של יותר מ-60 שניות בין סיום הבלוק הנוכחי לתחילת הביקור הבא, נפתח בלוק חדש. השוואות מבוצעות רק **בתוך** אותו בלוק, מה שהופך את הבעיה למעשית מבחינה חישובית.

שלב 2 — קריטריון האיחוד: שני ביקורים מועמדים לאיחוד אם (א) הם חופפים בזמן או שהפער ביניהם קטן מ-60 שניות, **וגם** (ב) ההפרש במגמת ה-RSSI שלהם קטן מסף מסוים. עבור ביקורי קריאה-בודדת (שאין להם מגמה מוגדרת) מופעל מנגנון גיבוי: השוואת RSSI הממוצע במקום המגמה. **לא** נעשה שימוש במרחק משוקלל יחיד המשלב זמן ו-RSSI (כפי שנהוג ב-DBSCAN קלאסי), כדי להימנע מהצורך להמציא משקל שרירותי בין שתי יחידות מידה שונות לחלוטין (שניות מול dBm/שנייה) ללא נתוני אמת לכיול המשקל הזה.

שלב 3 — קביעת הסף: סף הדמיון במגמה (וב-RSSI הממוצע, במנגנון הגיבוי) נקבע כ**אחוזון ה-10** של התפלגות ההפרשים בין כל זוגות הביקורים המועמדים — בחירה שמרנית שמעדיפה לפספס איחודים אמיתיים (false negative) על פני ליצור איחוד שגוי (false positive), מכיוון שאין נתוני אמת לכייל סף מדויק יותר.

שלב 4 — קיבוץ (Clustering): בתוך כל בלוק, מבוצע קיבוץ היררכי (**hierarchical clustering**) בשיטת **Complete-Linkage** ("מרחק מקסימלי"): קבוצה מתקבלת רק אם **כל** הזוגות בתוכה — לא רק זוגות סמוכים — עומדים בסף הדמיון. זו הכרעה מתודולוגית מרכזית: בשיטת Single-Linkage ("שרשור פשוט", כל זוג סמוך בשרשרת) מספיק ששני ביקורים סמוכים יהיו דומים כדי שיתמזגו, כך שקצוות רחוקים בשרשרת (ביקור 1 מול ביקור 400+) עלולים להתמזג בעקיפין אף שאינם דומים כלל זה לזה — תופעה שנצפתה בפועל בבדיקות המוקדמות של שיטה זו (קבוצה של מאות ביקורים עם טווח מגמות בלתי סביר לחלוטין עבור אדם אחד). Complete-Linkage חסין לבעיה זו במבנה שלו.

למה נבחרה השיטה הזו

יתרונות:

- שני קריטריונים נפרדים (זמן, מגמת RSSI) — לא נדרש משקל שרירותי בין יחידות מידה שונות.
- Complete-Linkage מבטיח שכל מי שמאוחד תחת אותו Traveler_ID באמת דומה לכולם בקבוצה, לא רק לשכן הקרוב בשרשרת.
- חסימה בזמן הופכת את הבעיה לחישובית ומעשית (סכום ריבועי גדלי-בלוק, לא ריבוע כל הנתונים).
- סף שמרן (אחוזון 10) מקטין את הסיכון לאיחוד-יתר שגוי במחיר מסוים של פיצול-יתר.

מגבלות:

- **אין נתוני אמת** — לא ניתן לחשב Precision/Recall אמיתיים; הבחירות (אחוזון 10, Complete-Linkage) מבוססות על סבירות סטטיסטית ולא על אימות.
- Complete-Linkage "נוקשה" מבנית: ביקור מועמד יחיד עם קריאה חריגה יכול למנוע איחוד קבוצה שאחרת הייתה סבירה.
- **קבוצת הליכה יחד ≠ מטייל מרובה-מכשירים:** אנשים ההולכים יחד באותו קצב ובאותו שביל מייצרים חפיפת זמן ומגמת RSSI דומות באופן טבעי. אין דרך להבחין בין "אדם אחד עם 5 מכשירים" ל"5 אנשים שהולכים יחד" מתוך נתוני BLE בלבד. ההחלטה הייתה להשאיר את התוצאה כפי שהיא ולדווח קבוצות גדולות

במפורש לבקרה ידנית, במקום להטיל תקרה שרירותית על מספר מכשירים לאדם.

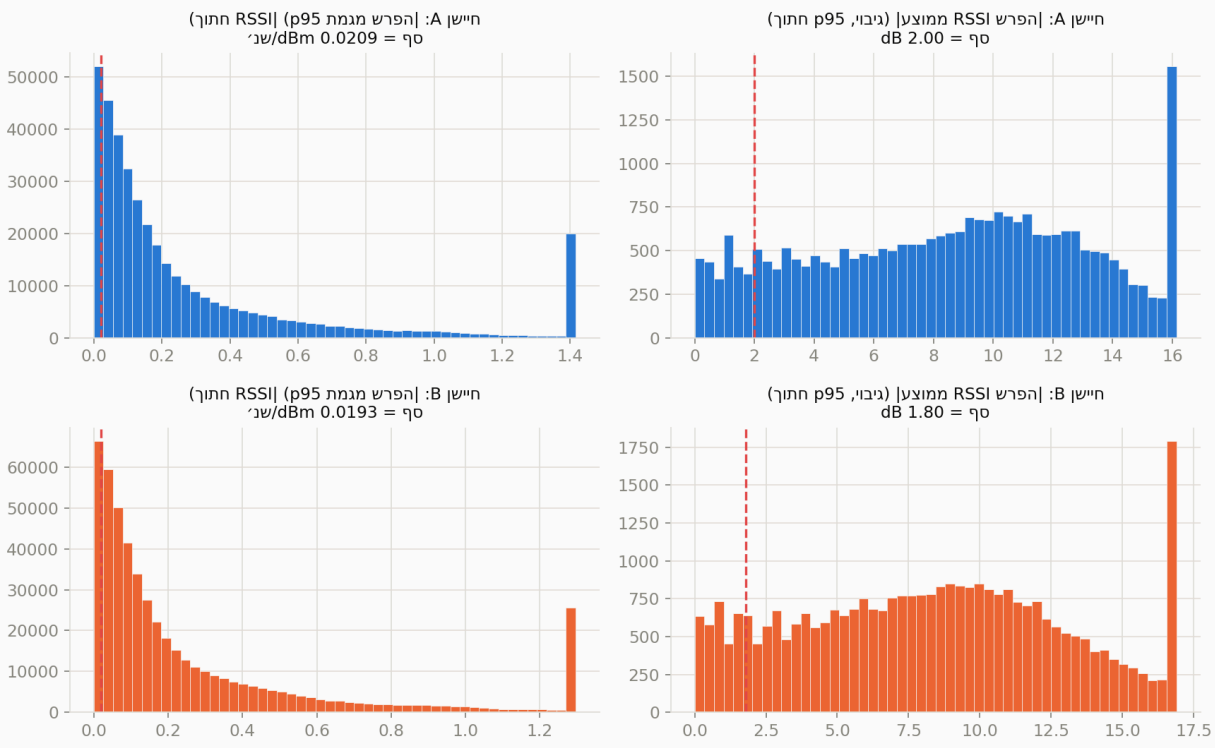
תוצאות

חיישן	ביקורים	מטיילים (Traveler_ID)	איחודים שבוצעו	הקבוצה הגדולה ביותר
A	15,267	7,961	7,306	17 מכשירים
B	19,359	10,516	8,843	22 מכשירים

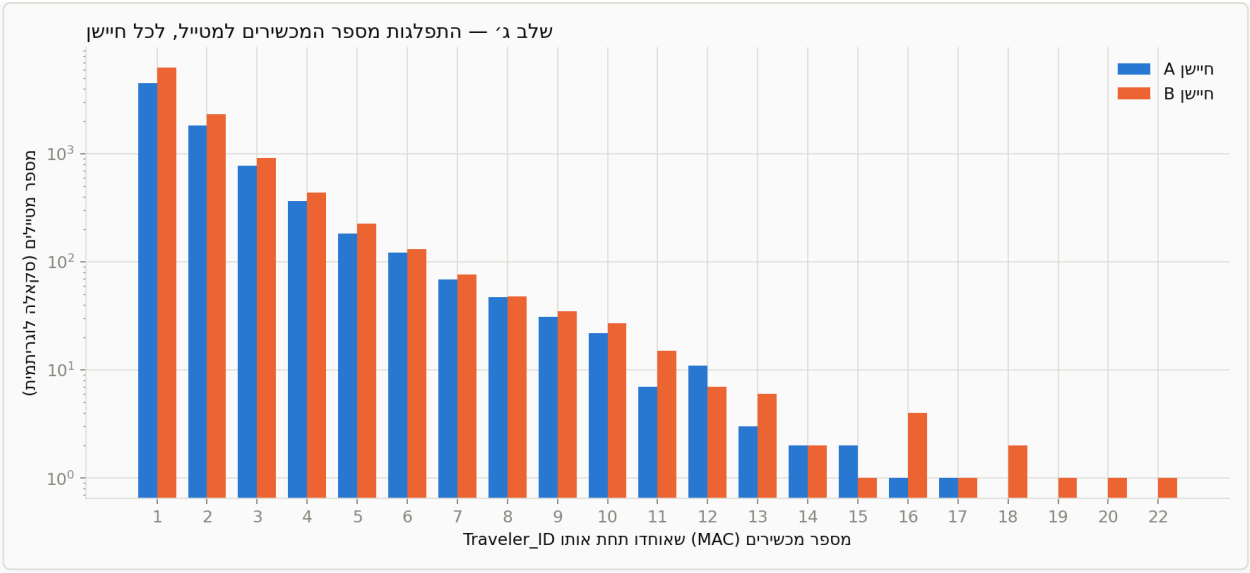
סף הדמיון שחושב בפועל (אחוזון 10):

חיישן	סף הפרש מגמת RSSI	סף גיבוי (הפרש RSSI ממוצע)
A	0.0209 dBm/שנייה	2.00 dB
B	0.0193 dBm/שנייה	1.80 dB

שלב ג׳ — בחירת סף האיחוד: התפלגות ההפרשים בין זוגות ביקורים מועמדים



התפלגות ההפרשים בין זוגות ביקורים מועמדים לאיחוד, בכל חיישן ובכל קריטריון (מגמה / גיבוי RSSI ממוצע) בנפרד. קו הסף (אדום מקווקו) נבחר באחוזון ה-10 — בחירה שמרנית שמעדיפה מיזוגים בטוחים על פני כמות.



התפלגות מספר המכשירים שאוחדו תחת אותו מטייל (סקאלה לוגריתמית). כ-56–60% מהמטיילים זוהו במכשיר אחד בלבד; הזנב הארוך (עד 17–22 מכשירים) הן הקבוצות הגדולות שנדונו במגבלות למעלה — ומיועדות לבקרה ידנית, לא לפירוק אוטומטי.

דוגמה: המטיילים עם מספר המכשירים הגבוה ביותר

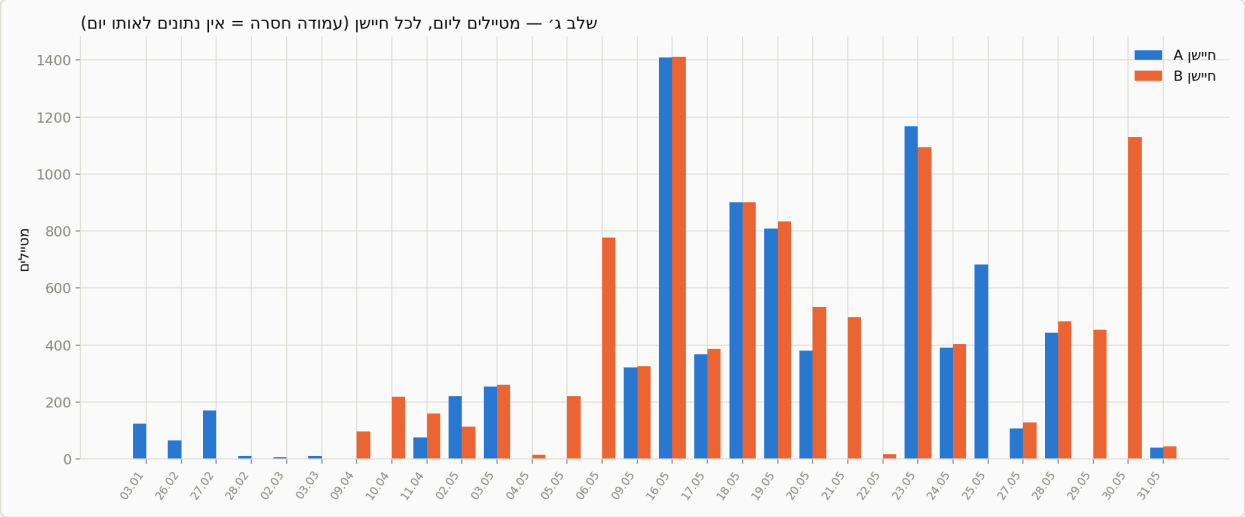
חיישן	Traveler_ID	מכשירים	תחילת ביקור	סיום ביקור	משך כולל (שנ׳)
A	A-198-47	17	10:31:50 19.05.2026	10:42:23 19.05.2026	3,441
A	A-329-121	16	11:03:56 25.05.2026	11:28:17 25.05.2026	5,679
B	B-630-88	22	13:25:21 30.05.2026	13:29:59 30.05.2026	2,929
B	B-630-76	20	13:23:16 30.05.2026	13:30:03 30.05.2026	2,954

תוצרים

קובץ	תיאור
`DATA/sessions_sensor_A/B_with_traveler .csv/.parquet`	טבלת ביקורים + עמודת Traveler_ID
`DATA/travelers_sensor_A/B .csv/.parquet`	טבלת סיכום ברמת המטייל (מספר מכשירים, טווח זמן וכו׳)
`DATA/travelers_per_day .csv/.parquet`	מספר מטיילים ליום, לכל חיישן

6. תוצאות מסכמות: מטיילים ליום

מספר המטיילים הייחודיים (לאחר איחוד זהויות) שזוהו בכל יום איסוף, בכל חיישן בנפרד. "היום" של מטייל נקבע לפי תאריך תחילת הביקור (`start_time`); נבדק ואומת שאף ביקור, בשני החיישנים, אינו חוצה חצות — כך שההקצאה ליום חד-משמעית.



עמודה חסרה = אין נתונים לאותו יום מאותו חיישן (ולא אפס מטיילים). בימים המשותפים, גובה העמודה הכחולה (A) והכתומה (B) קרוב מאוד זה לזה.

תאריך	מטיילים — חיישן A	מטיילים — חיישן B
03.01.2026	125	
26.02.2026	66	
27.02.2026	170	
28.02.2026	10	
02.03.2026	7	
03.03.2026	10	
09.04.2026		97
10.04.2026		219
11.04.2026	77	160
02.05.2026	220	114
03.05.2026	255	261
04.05.2026		16
05.05.2026		221
06.05.2026		778
09.05.2026	322	326
16.05.2026	1,410	1,412

17.05.2026	368	387
18.05.2026	902	901
19.05.2026	808	834
20.05.2026	380	533
21.05.2026		499
22.05.2026		18
23.05.2026	1,167	1,095
24.05.2026	390	404
25.05.2026	683	
27.05.2026	107	128
28.05.2026	444	484
29.05.2026		454
30.05.2026		1,130
31.05.2026	40	45

בדיקת עקביות בין החיישנים (Cross-check עצמאי): מתוך 30 ימי איסוף שונים, 7 ימים (03.01, 26–28.02, 02–03.03, 25.05) קיימים בחיישן A בלבד, ו-9 ימים קיימים בחיישן B בלבד (09–10.04, 04–06.05, 21–22.05, 29–30.05) — ככל הנראה בשל הבדלי זמינות/הפעלה בפועל של כל חיישן, ולא כתוצאה מתקלת עיבוד. ב-14 הימים המשותפים, הספירות היומיות של שני החיישנים — שכל אחד מהם מחושב על ידי צינור עיבוד נפרד ובלתי-תלוי לחלוטין — קרובות מאוד זו לזו (למשל 18.05: 902 מול 901; 16.05: 1,410 מול 1,412; 19.05: 808 מול 834). זו בדיקת תקינות עצמאית ומעודדת: היא לא מוכיחה שהספירה המוחלטת נכונה (עדיין אין נתוני אמת), אך כן מראה ששני היישומים הנפרדים של אותה שיטה מתכנסים לאותה תשובה בקירוב טוב.

7. יתרונות ומגבלות של הגישה הכוללת

יתרונות מערכתיים:

- **עלות ופרטיות:** חיישני BLE זולים משמעותית ממצלמות או אינפרה-אדום, אינם דורשים קו-ראייה ישיר, פועלים ביום ובלילה, ואינם צריכים לצלם את המבקרים — נשמרות רק כתובות MAC מוצפנות/מוחלפות מתוך פרוטוקול BLE עצמו.
- **פסיביות מלאה:** אין צורך שהמטייל יתקין אפליקציה, יישא תג, או ינקוט בכל פעולה — הזיהוי מתבסס על שידורי BLE שהמכשירים משדרים ממילא כברירת מחדל.
- **אימות הדדי בין שני צינורות עצמאיים:** העובדה שחיישן A וחיישן B — שני יישומים נפרדים לחלוטין של אותה שיטה, על נתונים חלקית שונים — מגיעים למספרים קרובים מאוד בימים המשותפים, היא עדות עקיפה חשובה לכך שהשיטה יציבה ולא רגישה יתר על המידה לרעש בנתונים.
- **שקיפות מתודולוגית:** כל סף (60 שניות, אחוזון 10) נגזר ישירות מהתפלגות הנתונים ומתועד, ולא "מכוון" ידנית לקבל תוצאה רצויה מראש.

מגבלות מערכתיות:

- **אין נתוני אמת בשום שלב** — לא ניתן לחשב דיוק (accuracy), רגישות (recall) או דיוק חיובי (precision) אמיתיים. כל הכיולים (סף הפער, סף הדמיון) מבוססים על סבירות סטטיסטית של ההתפלגות עצמה, לא על השוואה לספירה ידנית מאומתת.
- **שני כיווני שגיאה מנוגדים, ללא דרך למדוד את המאזן ביניהם:** מצד אחד, החלפת MAC "אגרסיבית" (שמתרחשת ממש בזמן שהמכשיר גם זז וגם משנה כתובת) עלולה ליצור קפיצת מגמה חדה מדי לאיחוד — וגורמת לספירת-יתר. מצד שני, קבוצת אנשים ההולכת יחד עלולה להתאחד בטעות לכדי "מטייל" אחד — וגורמת לספירת-חסר. בלי נתוני אמת, לא ידוע איזה כיוון שגיאה דומיננטי, או אם הם מקזזים זה את זה.
- **פערי כיסוי בין החיישנים:** רק 14 מתוך 30 ימי איסוף כוללים נתונים משני החיישנים במקביל — בשאר הימים לא ניתן (וגם לא יינתן בעתיד, שלב ד׳) לחשב כיוון תנועה.
- **ביקורי קריאה-בודדת (כ-4% מהביקורים בשני החיישנים)** מספקים מידע חלש במיוחד לשלב האיחוד (רק RSSI ממוצע, ללא מגמה) — נוטים להישאר לא מאוחדים גם כאשר הם אכן שייכים למטייל שכבר זוהה.
- **קובץ 03.01.2026 הוא חריג הקשרי:** חלון של שעה בודדת, כחודשיים לפני שאר האיסוף, ללא נתוני חיישן B מקבילים — לא ידוע אם תנאי השטח (עונה, עומס מטיילים) דומים לשאר הנתונים, ולכן יש להתייחס למספר 125 המטיילים שהתקבל עבורו בזהירות יחסית כנקודת נתון בודדת.

8. השלב הבא: שלב ד׳ — זיהוי כיוון תנועה

שלב	תיאור	סטטוס
א׳	ניקוי והכנת נתונים	**הושלם**
ב׳	חלוקה לביקורים והנדסת מאפיינים	**הושלם**
ג׳	איחוד זהויות (Traveler_ID)	**הושלם**
ד׳	זיהוי כיוון תנועה (ΔRSSI בין החיישנים)	**טרם תוכנן**

שלב ד׳ ישתמש בהפרש העוצמה בין שני החיישנים (`ΔRSSI = RSSI_B − RSSI_A`) באזור החפיפה הפיזי כדי לקבוע כיוון הליכה: אם ΔRSSI עובר ממינוס (A חזק יותר) לפלוס (B חזק יותר) ככל שהמטייל מתקדם, ניתן להסיק כיוון הליכה מבלי להסתמך על סנכרון מיקרו-שניות מדויק בין החיישנים. השלב ידרוש בנוסף התאמה בין-חיישנית בין מטיילים שזוהו בחיישן A למטיילים שזוהו בחיישן B (קישור זהויות חוצה-חיישן) — משימה שלא טופלה במכוון בשלב ג׳, שם כל חיישן עובד באופן בלתי-תלוי. יש לשים לב שהשלב הזה יהיה ישים רק על 14 הימים המשותפים לשני החיישנים; שאר 16 הימים (כולל קובץ 03.01.2026 החדש) לא יוכלו לקבל תוצאת כיוון-תנועה כלל.

דוח זה מסכם את מצב המחקר והמתודולוגיה נכון ל-30 ביולי 2026, ומבוסס על הרצה מלאה ועדכנית של שלושת השלבים (מחברות `notebooks/01` – `03`) מול כל קבצי הנתונים הזמינים כיום, כולל `data_A_030126.xlsx` . כל הקבצים, המחברות ומסמכי התכנון המפורטים (`docs/specs/`) נמצאים בתיקיית הפרויקט `bluetooth_projet` .