סיכום פרויקט: ניטור מטיילים מבוסס חיישני BLE

דוח התקדמות — 29 ביולי 2026 | שלבים א׳–ג׳ מתוך ד׳ הושלמו (עודכן לאחר קבלת נתוני חיישן A המלאים)

מטרת הפרויקט היא לבנות מערכת מבוססת חיישני Bluetooth (BLE) לספירת מטיילים בשטח, תוך פתרון שתי בעיות מרכזיות: מטייל אחד עשוי לשאת מספר מכשירים (טלפון, שעון, אוזניות), ומכשירים משנים את כתובת ה-MAC שלהם מטעמי פרטיות. שני האתגרים גורמים לספירת יתר. הפתרון נבנה כצינור עיבוד (pipeline) בן ארבעה שלבים, המתועד בקובץ `hiker_monitoring_project_summary.md`. דוח זה מסכם את שלושת השלבים שבוצעו עד כה, כולל תוצאות מספריות ושני ממצאים מהותיים שהתגלתו ותוקנו תוך כדי עבודה — האחד באלגוריתם האיחוד (שלב ג׳), והשני בנתוני הקלט עצמם (שלב א׳).

> **עדכון מרכזי:** לאחר כתיבת הדוח המקורי התקבל קובץ הנתונים המלא של חיישן A (`Sensor_A_combined_file.xlsx`), הכולל חותמות זמן אמיתיות ברזולוציית שניות לכל שורה — במקום החילוץ החלקי שהיה זמין קודם ברזולוציית דקה בלבד. בבדיקה התברר ששלב הניקוי המקורי (המבוסס על התאמת דקה) ביצע ספירת חסר: קריאות שונות שנפלו באותה דקה נחשבו בטעות לכפילות וכוסו זו את זו. שלבים א׳–ג׳ שוחזרו במלואם מול הנתונים המתוקנים; המספרים בדוח זה הם התוצאות הסופיות.

638,254	815,093	10,516 / 7,838
רשומות חיישן A לאחר ניקוי (עודכן)	רשומות חיישן B לאחר ניקוי	מטיילים (A / B) לאחר איחוד זהויות

שלב א׳: הכנת נתוני חיישן A

הרקע (המצב המקורי): חיישן A היה זמין תחילה רק בקובץ שמר חותמות זמן ברזולוציה של דקה בלבד (ללא שניות), בעוד שחיישן B שמר ברזולוציית שניות. השלב המקורי שיחזר שניות משוערות באמצעות פיזור ליניארי של הקריאות בתוך כל דקה.

הבעיה שהתגלתה: לאחר שהתקבל הקובץ המלא של חיישן A (`Sensor_A_combined_file.xlsx` , 945,642 שורות) — הכולל חותמות זמן אמיתיות ברזולוציית שניות לכל שורה, ולא רק לחלק מהן — התברר ששלב הניקוי המקורי לא היה רק "משוער" אלא **שגוי בפועל**: מכיוון שהניקוי הישן זיהה כפילויות לפי (MAC, RSSI, timestamp) ברמת דקה, שתי קריאות שונות לחלוטין של אותו MAC עם אותו RSSI שנפלו באותה דקה נחשבו בטעות לאותה קריאה ומוזגו יחד. הרצת אותו ניקוי בדיוק על הנתונים החדשים (עם שניות אמיתיות) נותנת **638,254** שורות במקום 347,148 הישנות — פער של כמעט פי שניים, שנבע כולו מהתנגשויות שווא ברמת הדקה, לא מכפילויות אמיתיות.

מה בדיוק השתנה בקובץ החדש

מתוך שבעת קבצי המקור, שישה זהים לחלוטין בכמות השורות לגרסה הקודמת. הקובץ היחיד שהשתנה מהותית הוא `dataA_110426_1_good.csv` : בגרסה הישנה הכיל רק 3,837 שורות (חלון של 75 דקות ב-11.04.2026), ואילו בגרסה החדשה הוא מכיל 34,125 שורות הפרושות על פני **46 ימים, מ־26.02.2026 עד 11.04.2026**. כלומר, התקבלו בפועל שישה שבועות נוספים של נתוני חיישן A שלא היו ידועים כלל קודם — תקופה שקודמת אף לתחילת נתוני חיישן B (9.04.2026), כך שלקטע הזה אין כלל נתוני חיישן B מקבילים.

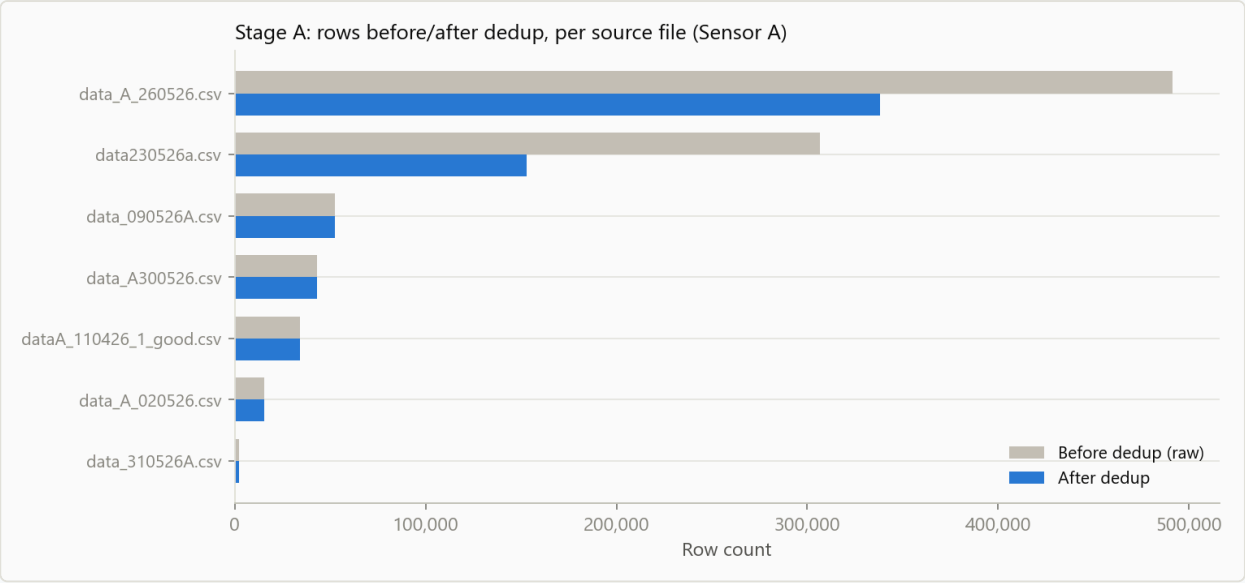
ממצא נוסף שנשמר: כפילות ייצוא מצטבר בין קבצים

כפי שנמצא כבר בגרסה הקודמת, חלק מקבצי המקור הם ייצוא מצטבר (cumulative) של אותו יומן מכשיר — קובץ מאוחר יותר מכיל בתוכו את כל הנתונים של קובץ מוקדם יותר, ועוד. לדוגמה: `data230526a.csv` הוא תת-קבוצה כמעט מלאה של `data_A_260526.csv` . בעיה זו עדיין קיימת בקובץ החדש ומטופלת באותה שיטה.

הפתרון המעודכן

1. טעינת `Sensor_A_combined_file.xlsx` — כל השורות כבר כוללות חותמת זמן ברזולוציית שניות, כך ש**שלב שחזור השניות אינו נדרש עוד**.
2. ניקוי כפילויות גלובלי לפי השילוש `(MAC, RSSI, timestamp)` ברמת השנייה המדויקת, על פני כל הקבצים יחד — הפחית את הנתונים מ־945,642 ל־638,254 שורות (הוסרו 307,388 כפילויות אמיתיות).
3. בדיקות תקינות: מונוטוניות חותמות הזמן לכל קובץ מקור, ודיווח כפילויות שהוסרו לכל קובץ בנפרד.

המחשה: כמה שורות נגרעו בניקוי, לכל קובץ מקור



עמודה אפורה = לפני ניקוי, עמודה כחולה = אחרי ניקוי. שני הקבצים הגדולים (data_A_260526, data230526a) מאבדים הכי הרבה שורות — עקבי עם ממצא הכפילות המצטברת.

איך הנתונים נראים אחרי השלב (דוגמת שורות)

`DATA/sensor_A_deduped.parquet` — 638,254 שורות:

MAC	RSSI	timestamp	source_file
71:11:b2:fd:ef:d5	-97	2026-02-26 11:51:41	dataA_110426_1_good.csv
0e:42:cc:bc:72:de	-96	2026-02-26 11:58:12	dataA_110426_1_good.csv
0e:42:cc:bc:72:de	-96	2026-02-26 11:58:13	dataA_110426_1_good.csv
3d:92:a3:a8:4c:d1	-95	2026-02-26 11:58:13	dataA_110426_1_good.csv
3d:92:a3:a8:4c:d1	-97	2026-02-26 11:58:13	dataA_110426_1_good.csv

תוצרים

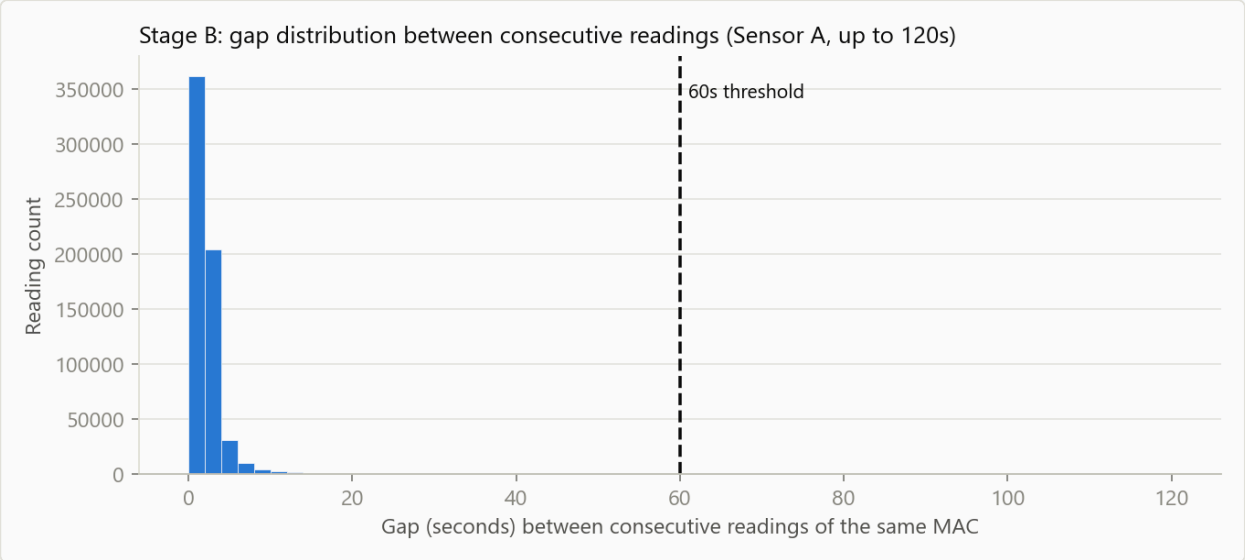
קובץ	תיאור
`DATA/sensor_A_deduped.csv / .parquet`	נתוני חיישן A לאחר ניקוי (ללא צורך בשחזור שניות)
`notebooks/01_stage_a_time_reconstruction.ipynb`	המחברת המלאה (שם הקובץ נשמר לצורך המשכיות, אף שהשחזור עצמו כבר לא נדרש)

שלב ב׳: חלוקה ל"ביקורים" והנדסת מאפיינים

המטרה: לקבץ קריאות RSSI גולמיות, עבור כל כתובת MAC ובכל חיישן בנפרד, ל"ביקורים" (sessions) רציפים, ולחלץ עבור כל ביקור מאפיינים שישמשו את שלבי ההמשך. **שלב זה שוחזר** לאחר תיקון שלב א׳, מול נתוני חיישן A המתוקנים.

קביעת סף הפרדה בין ביקורים

נבדקה מחדש התפלגות הפערים בין קריאות עוקבות של אותה כתובת MAC על הנתונים המתוקנים: החציון הוא שנייה אחת, ו־99.9% מהפערים קטנים או שווים ל־60 שניות — עקבי עם הבדיקה הקודמת (99.8%). סף ה־**60 שניות** נותר תקף.



רוב הפערים מתרכזים קרוב לאפס; קו השבר (60 שניות) נבחר כנקודת החיתוך הטבעית בין "עדיין באזור הקליטה" לבין "התרחק/עזב".

הכנת נתוני חיישן B

ללא שינוי: אותה בעיית כפילות ייצוא מצטבר קיימת גם בחיישן B — 1,217,216 שורות גולמיות צומצמו ל־815,093 לאחר ניקוי זהה. חיישן B כבר שומר רזולוציית שניות, כך שלא נדרש שחזור זמנים עבורו — רק ניקוי כפילויות.

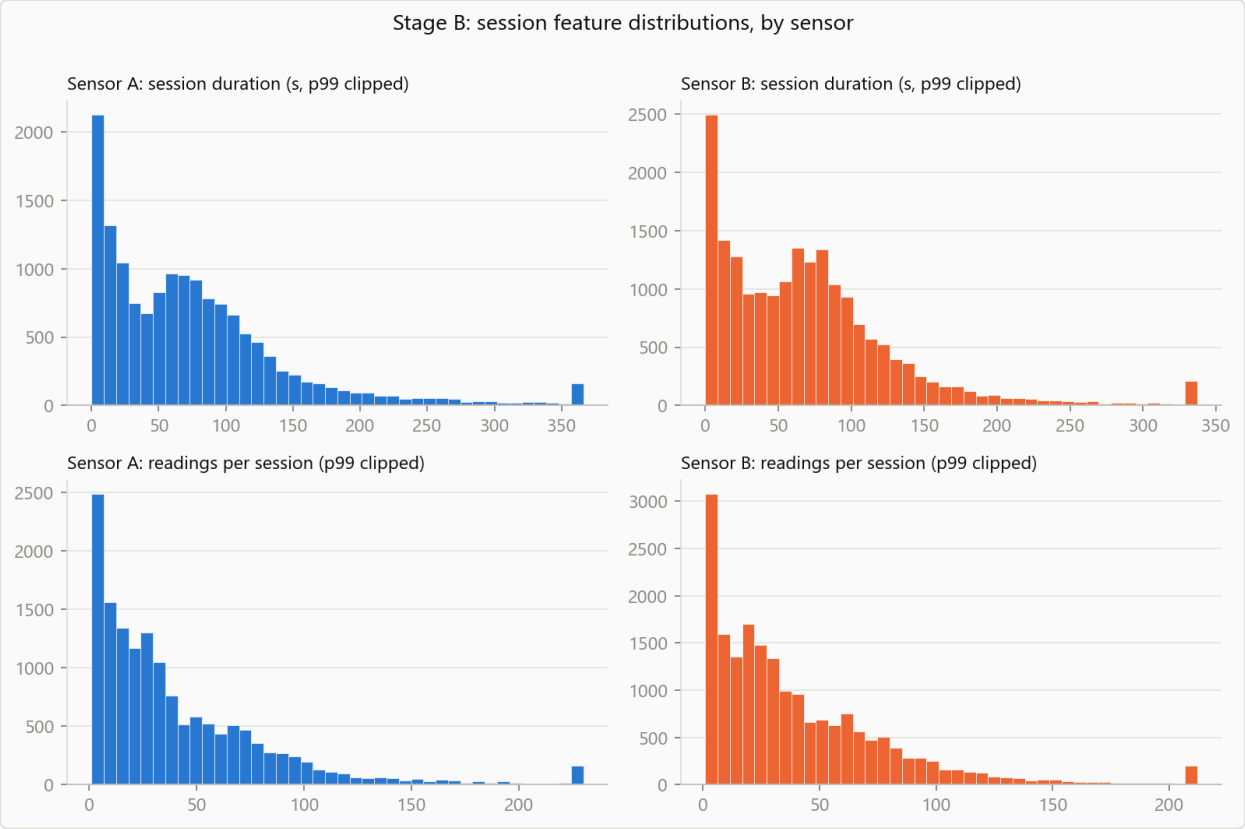
מאפיינים שחולצו לכל ביקור

- זמן התחלה וסיום, ומשך השהות
- מספר קריאות בביקור
- עוצמת קליטה ממוצעת (Mean RSSI)
- **מגמת RSSI (rssi_trend):** שיפוע ריבועים-פחותים (linear regression) של RSSI כנגד הזמן בתוך הביקור — בביקורים עם קריאה בודדת השיפוע אינו מוגדר (`NaN`), וזה נשמר במכוון ולא הושלך

תוצאות (מעודכן)

חיישן	קריאות (לאחר ניקוי)	ביקורים (sessions)	ביקורים עם קריאה בודדת
A	638,254	15,093	643
B	815,093	19,359	801

לשם השוואה: לפני התיקון, 347,148 קריאות חיישן A הניבו 14,661 ביקורים. כלומר, רוב הקריאות ש"נוספו" בתיקון (כ־291K) התווספו לביקורים קיימים ולא יצרו הרבה ביקורים חדשים — עדות לכך שהתיקון בעיקר צפיפות מדגם ולא זיהוי ביקורים חדשים.



התפלגות משך הביקור ומספר הקריאות לביקור, בשני החיישנים — צורות דומות מאוד בין A ל-B, עוד סימן לעקביות בין שני הצינורות הנפרדים.

איך הנתונים נראים אחרי השלב (דוגמת שורות)

`DATA/sessions_sensor_A.parquet` — 15,093 שורות:

sensor	MAC	session_id	start_time	end_time	duration_s	n_readings	mean_rssi	rssi_trend
A	00:01:a5:f1:dc:c0	1	2026-05-19 11:28:31	2026-05-19 11:28:55	24.0	14	-91.86	-0.0917
A	00:05:12:18:96:8a	2	2026-05-23 11:57:46	2026-05-23 11:58:11	25.0	15	-97.07	0.1026
A	00:09:b2:fb:f4:36	3	2026-05-19 14:06:37	2026-05-19 14:07:55	78.0	47	-87.98	-0.0116
A	00:0d:40:9e:7c:59	4	2026-05-24 10:30:39	2026-05-24 10:30:53	14.0	4	-93.25	-0.5522
A	00:0d:5f:3a:4a:fb	5	2026-02-26 13:41:28	2026-02-26 13:42:05	37.0	8	-96.13	-0.0610

תוצרים

קובץ	תיאור
`DATA/sessions_sensor_A / B .csv / .parquet`	טבלת ביקורים לכל חיישן, עם כל המאפיינים
`notebooks/02_stage_b_sessionization.ipynb`	המחברת המלאה

שלב ג׳: איחוד זהויות (Entity Resolution)

המטרה: לאחד כתובות MAC שונות ששייכות ככל הנראה לאותו מטייל פיזי (בשל ריבוי מכשירים או שינוי כתובת MAC באמצע ביקור) תחת מזהה מטייל יחיד (Traveler_ID). הפעולה מתבצעת בנפרד עבור כל חיישן. **שלב זה שוחזר** לאחר תיקון שלבים א׳-ב׳, כאשר האלגוריתם עצמו לא השתנה.

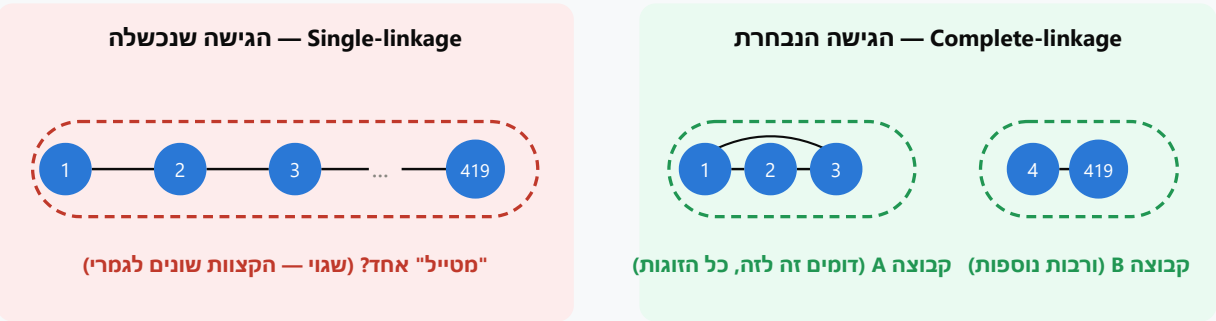
העיקרון

שני ביקורים מאוחדים אם הם חופפים בזמן (או שהפער ביניהם קטן מ־60 שניות) **וגם** מגמת ה-RSSI שלהם דומה מאוד. לא נעשה שימוש במרחק משוקלל יחיד (כפי שהיה נהוג ב־DBSCAN קלאסי), כדי להימנע מהצורך להמציא משקל שרירותי בין שתי יחידות מידה שונות (שניות מול dBm/שנייה) ללא נתוני אמת (ground truth) לכיול.

בעיה שהתגלתה בבדיקה הראשונה (באלגוריתם, לא בנתונים): הגישה הראשונית (רכיבים קשירים / single-linkage) יצרה "מטייל" אחד המורכב מ־419 ביקורים שונים, כאשר מגמת ה-RSSI בתוכו נעה בין `-2.0` ל־`+6.0` dBm/שנייה — טווח בלתי סביר לחלוטין עבור אדם אחד. הסיבה: שרשור טרנזיטיבי (ביקור 1 דומה ל-2, 2 דומה ל-3, וכן הלאה), כך שגם אם כל זוג סמוך עומד בסף, הקצוות הרחוקים בשרשרת יכולים להיות שונים לגמרי.

התיקון: מעבר לאלגוריתם **Complete-Linkage** (קיבוץ היררכי עם קריטריון "מרחק מקסימלי") בתוך כל בלוק זמן. בשיטה זו קבוצה מתקבלת רק אם **כל** הזוגות בתוכה (ולא רק זוגות סמוכים בשרשרת) עומדים בסף הדמיון — מה שמבטל את בעיית השרשור מבנית. לאחר התיקון (ומאז גם על הנתונים המתוקנים של שלב א׳), הקבוצה הגדולה ביותר נותרה בטווח סביר של 17–22 מכשירים.

המחשת האלגוריתם: מדוע שרשור נכשל ומה Complete-Linkage עושה אחרת



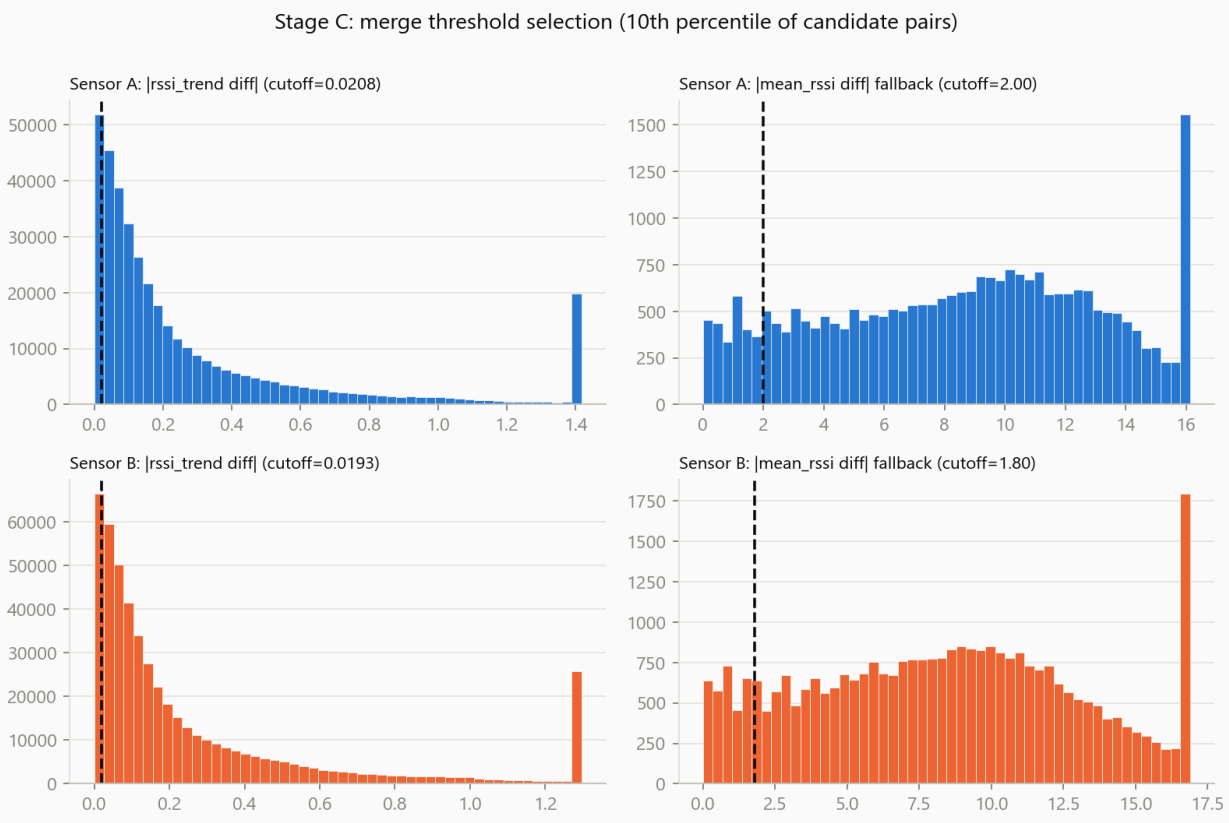
בגישת ה-single-linkage, מספיק ששני ביקורים סמוכים בשרשרת יהיו דומים כדי שיתמזגו — כך הקצוות הרחוקים (1 מול 419) מתמזגים בעקיפין אף שאינם דומים כלל. ב-complete-linkage, קבוצה מתקבלת רק אם **כל** הזוגות בתוכה עומדים בסף — מה שמבטיח שכל מי שמאוחד תחת אותו Traveler_ID באמת דומה לכולם, לא רק לשכן שלו.

מגבלה ידועה שהתקבלה במודע

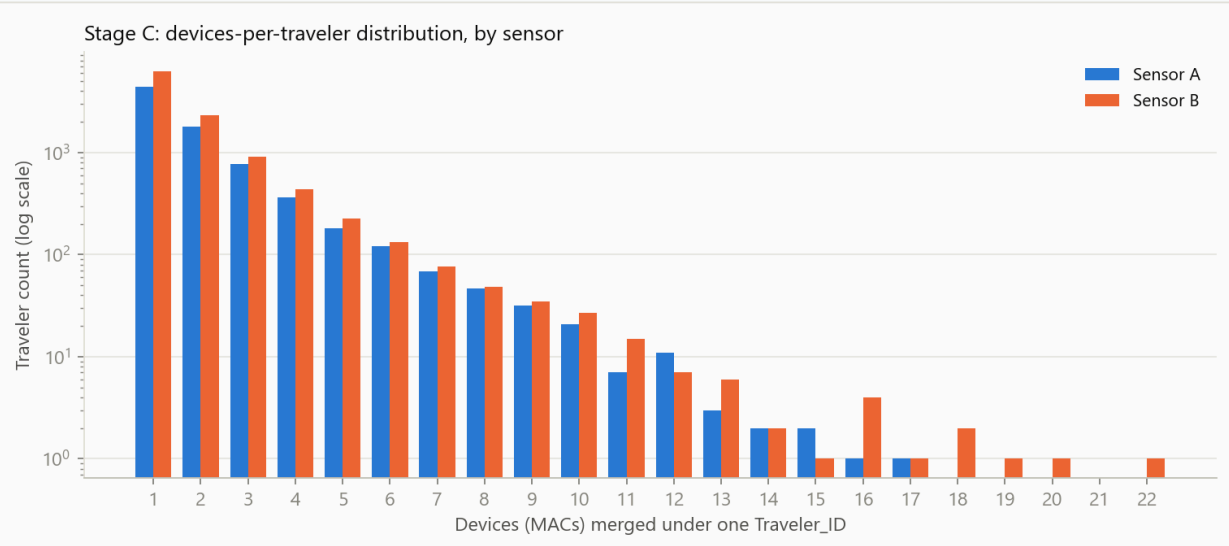
גם לאחר התיקון, הקבוצות הגדולות ביותר (עד כ־17–22 מכשירים) עשויות לייצג **קבוצת מטיילים ההולכים יחד** ולא בהכרח מכשירים רבים של אדם אחד — אנשים ההולכים יחד באותו שביל ובאותו קצב מייצרים חפיפת זמן ומגמת RSSI דומות מטבע הדברים. אין דרך להבחין בין שתי האפשרויות מתוך נתוני ה-BLE בלבד, וללא נתוני אמת. ההחלטה הייתה להשאיר את התוצאה כפי שהיא, כאשר הקבוצות הגדולות מדווחות במפורש בבדיקות התקינות של המחברת לצורך בקרה ידנית — ולא לנסות "לנחש" באמצעות תקרה שרירותית על מספר המכשירים לאדם.

תוצאות (מעודכן)

חיישן	ביקורים	מטיילים (Traveler_ID)	איחודים שבוצעו	הקבוצה הגדולה ביותר
A	15,093	7,838	7,255	17 מכשירים
B	19,359	10,516	8,843	22 מכשירים



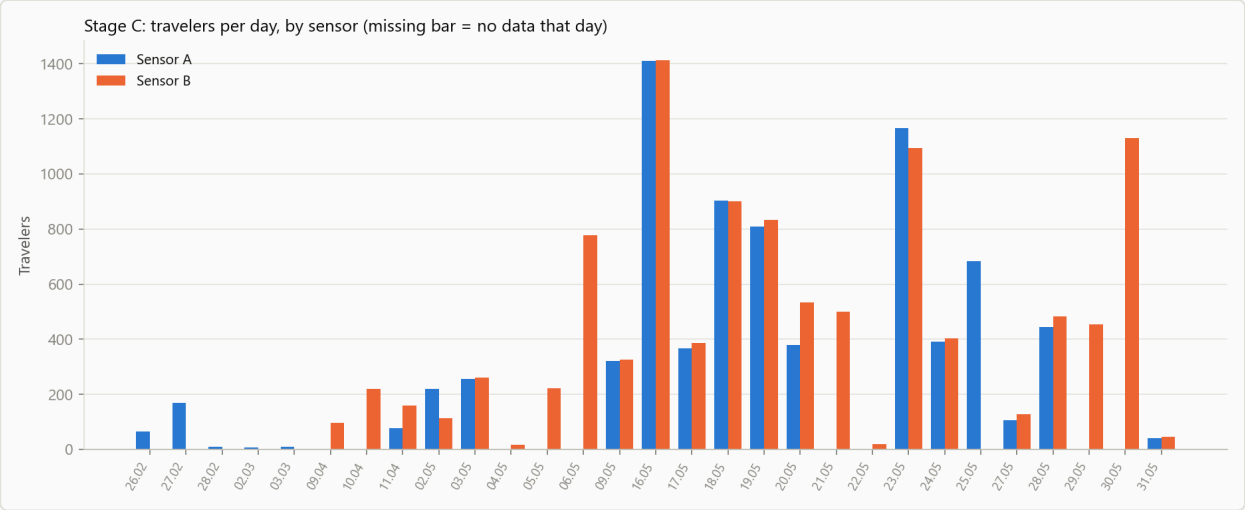
התפלגות ההפרשים בין זוגות ביקורים מועמדים לאיחוד (בכל חיישן בנפרד). הסף (קו מקווקו) נבחר כאחוזון ה־10 של ההתפלגות — בחירה שמרנית שמעדיפה מיזוגים בטוחים על פני כמות, מכיוון שאין נתוני אמת לכיול מדויק יותר.



רוב המטיילים (כ־55-60%) זוהו במכשיר אחד בלבד; מיעוט משמעותי אוחד משני מכשירים או יותר. הזנב הארוך (עד 17-22 מכשירים) הם הקבוצות הגדולות שנדונו במגבלה הידועה למטה.

מטיילים ליום, לכל חיישן (מעודכן — כולל טווח פברואר–מרץ החדש)

מספר המטיילים היחודיים (לאחר איחוד הזהויות) שזוהו בכל יום איסוף, בכל חיישן בנפרד. "היום" של מטייל נקבע לפי תאריך ה- `start_time` שלו — נבדק ואומת כי אף ביקור, בשני החיישנים, אינו חוצה חצות, כך שההקצאה חד-משמעית. חמישה ימים חדשים בפברואר-מרץ נוספו לחיישן A בעקבות תיקון שלב א׳.



עמודה חסרה = אין נתונים לאותו יום מאותו חיישן (ולא אפס מטיילים). בימים המשותפים, גובה העמודות הכחולה והכתומה קרוב מאוד זה לזה.

תאריך	מטיילים — חיישן A	מטיילים — חיישן B
26.02.2026	66	—
27.02.2026	170	—
28.02.2026	10	—
02.03.2026	7	—
03.03.2026	10	—
09.04.2026	—	97
10.04.2026	—	219
11.04.2026	77	160
02.05.2026	220	114
03.05.2026	255	261
04.05.2026	—	16
05.05.2026	—	221
06.05.2026	—	778
09.05.2026	322	326
16.05.2026	1,410	1,412
17.05.2026	368	387
18.05.2026	902	901

19.05.2026	809	834
20.05.2026	380	533
21.05.2026	—	499
22.05.2026	—	18
23.05.2026	1,167	1,095
24.05.2026	390	404
25.05.2026	684	—
27.05.2026	107	128
28.05.2026	444	484
29.05.2026	—	454
30.05.2026	—	1,130
31.05.2026	40	45

פערי כיסוי בין החיישנים: מתוך 29 ימי איסוף שונים (לאחר הוספת נתוני פברואר–מרץ לחיישן A), שישה ימים (26–28.02, 02–03.03, 25.05) קיימים בחיישן A בלבד, ותשעה ימים קיימים בחיישן B בלבד (09–10.04, 04–06.05, 21–22.05, 29–30.05) — כנראה בשל הבדלים בזמינות/פעילות בפועל של כל חיישן, ולא כתוצאה מבאג בעיבוד. עם זאת, ב־14 הימים שבהם לשני החיישנים יש נתונים, הספירות היומיות עדיין קרובות מאוד זו לזו (למשל 18.05: 902 מול 901; 19.05: 809 מול 834) — בדיקת תקינות עצמאית ומעודדת שנשארה תקפה גם לאחר התיקון, שכן שני הצינורות (A ו-B) מחושבים בנפרד לחלוטין זה מזה.

איך הנתונים נראים אחרי השלב (דוגמת שורות)

`DATA/travelers_sensor_A.parquet` — 7,838 שורות, ה-5 עם הכי הרבה מכשירים:

Traveler_ID	sensor	n_devices	MACs (first 2)	start_time	end_time	total_duration_s
A-189-47	A	17	48:a9:1c:68:44:f0, 53:3f:78:3b:81:4e ...	2026-05-19 10:31:50	2026-05-19 10:42:23	3441.0
A-320-121	A	16	04:19:f8:08:f9:69, 0e:79:9e:5f:50:3d ...	2026-05-25 11:03:56	2026-05-25 11:28:17	5679.0
A-161-14	A	15	41:92:28:3a:cd:f3, 42:af:e0:ed:07:71 ...	2026-05-18 12:20:23	2026-05-18 12:23:53	1325.0
A-196-13	A	15	02:98:1f:6a:c3:6d, 11:fd:e8:db:5d:ca ...	2026-05-19 12:18:16	2026-05-19 12:24:54	3013.0
A-376-71	A	14	28:8d:e9:3e:bb:3a, 3f:0b:5e:95:d6:c9 ...	2026-05-28 10:26:00	2026-05-28 10:29:55	1086.0

תוצרים

קובץ	תיאור
`DATA/sessions_sensor_A/B_with_traveler .csv/.parquet`	טבלת ביקורים + עמודת Traveler_ID
`DATA/travelers_sensor_A/B .csv/.parquet`	טבלת סיכום ברמת המטייל (מספר מכשירים, טווח זמן, וכו')
`DATA/travelers_per_day .csv/.parquet`	מספר מטיילים ליום, לכל חיישן
`notebooks/03_stage_c_entity_resolution.ipynb`	המחברת המלאה, כולל תיעוד הבאג והתיקון וניתוח יומי

מסמכי תכנון (Design Docs)

לכל שלב נכתב מסמך תכנון מפורט לפני היישום, כולל הנימוקים לכל החלטה. כל שלושת המסמכים עודכנו עם סעיף "Update" המתעד את השחזור מול נתוני חיישן A המלאים:

שלב	מסמך
א'	`docs/specs/2026-07-29-stage-a-time-reconstruction-design.md`
ב'	`docs/specs/2026-07-29-stage-b-sessionization-design.md`
ג'	`docs/specs/2026-07-29-stage-c-entity-resolution-design.md`

מצב נוכחי והצעד הבא

שלב	תיאור	סטטוס
א'	הכנת נתוני חיישן A (ניקוי כפילויות)	**הושלם (שוחזר)**
ב'	חלוקה לביקורים והנדסת מאפיינים	**הושלם (שוחזר)**
ג'	איחוד זהויות (Traveler_ID)	**הושלם (שוחזר)**
ד'	זיהוי כיוון תנועה (ΔRSSI בין החיישנים)	**טרם תוכנן**

השלב הבא, שלב ד', ישתמש בהפרש העוצמה בין שני החיישנים (`ΔRSSI = RSSI_B - RSSI_A`) כדי לקבוע כיוון הליכה, ובנוסף יידרש לבצע התאמה בין מטיילים שזוהו בחיישן A לבין אלו שזוהו בחיישן B (קישור בין-חיישני) — משימה שלא טופלה בשלב ג' במכוון. יש לשים לב שהקטע החדש של חיישן A (26.02–08.04.2026) לא יוכל להיות מותאם לחיישן B כלל, מאחר שאין לו נתוני חיישן B מקבילים.
